

Онлайн градиентный спуск

Онлайн градиентный спуск (online gradient descent, OGD) для начальной точки (базового решения) $x_1 \in \mathcal{D}$ и последовательности шагов $\{\alpha_t\}$ конструирует последовательность решений $\{x_t\}$ по следующим правилам:

- игрок в момент $t \in [1, T]$ принимает решение x_t и получает потери $f_t(x_t)$;
- осуществляется сдвиг и проектирование:

$$\begin{aligned} y_{t+1} &= x_t - \alpha_t \nabla f_t(x_t), \\ x_{t+1} &= \Pi_{\mathcal{D}}(y_{t+1}). \end{aligned}$$

Будем предполагать, что справедливы следующие утверждения:

- существует положительная постоянная D такая, что для любых $x', x'' \in \mathcal{D}$ справедливо неравенство $\|x' - x''\| \leq D$;
- существует положительная константа G такая, что для любой функции потерь $f \in \mathcal{F}$ и допустимого решения $x \in \mathcal{D}$ справедлива оценка $\|\nabla f(x)\| \leq G$.

Теорема 1. Для переменного шага $\alpha_t = \frac{D}{G\sqrt{t}}$ онлайн градиентный спуск обеспечивает следующую оценку на регрет:

$$\text{regret}_t(\text{OGD}) = \sum_{s=1}^t f_s(x_s) - \min_{x \in \mathcal{D}} \sum_{s=1}^t f_s(x) \leq \frac{3}{2}GD\sqrt{t}.$$

Доказательство. Пусть

$$x_* \in \arg \min_{x \in \mathcal{D}} \sum_{s=1}^t f_s(x).$$

В силу выпуклости функции $f_s(x)$ имеем неравенство

$$f_s(x_*) \geq f_s(x_s) + \langle \nabla f_s(x_s), x_* - x_s \rangle,$$

которое перепишем в виде

$$f_s(x_s) - f_s(x_*) \leq \langle \nabla f_s(x_s), x_s - x_* \rangle. \quad (1)$$

Далее,

$$\begin{aligned} \|x_{s+1} - x_*\|^2 &= \|\Pi_{\mathcal{D}}(x_s - \alpha_s \nabla f_s(x_s)) - x_*\|^2 \leq \|x_s - \alpha_s \nabla f_s(x_s) - x_*\|^2 = \\ &= \|x_s - x_*\|^2 + \alpha_s^2 \|\nabla f_s(x_s)\|^2 - 2\alpha_s \langle \nabla f_s(x_s), x_s - x_* \rangle, \end{aligned}$$

откуда

$$\begin{aligned} \langle \nabla f_s(x_s), x_s - x_* \rangle &\leq \frac{1}{2\alpha_s} (\|x_s - x_*\|^2 - \|x_{s+1} - x_*\|^2) + \frac{\alpha_s}{2} \|\nabla f_s(x_s)\|^2 \leq \\ &\leq \frac{1}{2\alpha_s} (\|x_s - x_*\|^2 - \|x_{s+1} - x_*\|^2) + \frac{\alpha_s}{2} G^2. \end{aligned}$$

Суммируем теперь (1) по s от 1 до t (полагая $\alpha_0 = +\infty$ в последующих выкладках):

$$\begin{aligned}
 \text{regret}_t(\text{OGD}) &= \sum_{s=1}^t (f_s(x_s) - f_s(x_*)) \leq \sum_{s=1}^t \langle \nabla f_s(x_s), x_s - x_* \rangle \leq \\
 &\leq \sum_{s=1}^t \frac{1}{2\alpha_s} (\|x_s - x_*\|^2 - \|x_{s+1} - x_*\|^2) + \frac{G^2}{2} \sum_{s=1}^t \alpha_s = \\
 &= \frac{1}{2} \sum_{s=1}^t \|x_s - x_*\|^2 \left(\frac{1}{\alpha_s} - \frac{1}{\alpha_{s-1}} \right) - \frac{\|x_{t+1} - x_*\|^2}{2\alpha_t} + \frac{G^2}{2} \sum_{s=1}^t \alpha_s \leq \\
 &\leq \frac{D^2}{2} \sum_{s=1}^t \left(\frac{1}{\alpha_s} - \frac{1}{\alpha_{s-1}} \right) + \frac{G^2}{2} \sum_{s=1}^t \alpha_s = \frac{D^2}{2\alpha_t} + \frac{G^2}{2} \sum_{s=1}^t \alpha_s = \\
 &= \frac{DG\sqrt{t}}{2} + \frac{DG}{2} \sum_{s=1}^t \frac{1}{\sqrt{s}} \leq \frac{3DG\sqrt{t}}{2}. \quad \square
 \end{aligned}$$

Теорема 2. Если семейство \mathcal{F} состоит из μ -сильно выпуклых функций потерь, то онлайн градиентный спуск с шагом $\alpha_t = 1/\mu t$ гарантирует следующую оценку на регресс:

$$\text{regret}_T(\text{OGD}) \leq \frac{G^2}{2\mu} (1 + \log T).$$

Доказательство. Поскольку функция $f_s(x)$ является μ -сильно выпуклой, то имеет место неравенство

$$f_s(x_*) \geq f_s(x_s) + \langle \nabla f_s(x_s), x_* - x_s \rangle + \frac{\mu}{2} \|x_* - x_s\|^2,$$

из которого

$$f_s(x_s) - f_s(x_*) \leq \langle \nabla f_s(x_s), x_s - x_* \rangle - \frac{\mu}{2} \|x_* - x_s\|^2. \quad (2)$$

Далее,

$$\begin{aligned}
 \|x_{s+1} - x_*\|^2 &= \|\Pi_{\mathcal{D}}(x_s - \alpha_s \nabla f_s(x_s)) - x_*\|^2 \leq \|x_s - \alpha_s \nabla f_s(x_s) - x_*\|^2 = \\
 &= \|x_s - x_*\|^2 + \alpha_s^2 \|\nabla f_s(x_s)\|^2 - 2\alpha_s \langle \nabla f_s(x_s), x_s - x_* \rangle,
 \end{aligned}$$

откуда

$$\langle \nabla f_s(x_s), x_s - x_* \rangle \leq \frac{1}{2\alpha_s} (\|x_s - x_*\|^2 - \|x_{s+1} - x_*\|^2) + \frac{\alpha_s}{2} G^2.$$

Таким образом,

$$\begin{aligned}
 \text{regret}_t(\text{OGD}) &= \sum_{s=1}^t (f_s(x_s) - f_s(x_*)) \leq \sum_{s=1}^t \left[\langle \nabla f_s(x_s), x_s - x_* \rangle - \frac{\mu}{2} \|x_* - x_s\|^2 \right] \leq \\
 &\leq \frac{G^2}{2} \sum_{s=1}^t \alpha_s + \frac{1}{2} \sum_{s=1}^t \|x_s - x_*\|^2 \left(\frac{1}{\alpha_s} - \frac{1}{\alpha_{s-1}} - \mu \right) = \\
 &= \frac{G^2}{2} \sum_{s=1}^t \alpha_t = \frac{G^2}{2\mu} \sum_{s=1}^t \frac{1}{t} = \frac{G^2}{2\mu} (1 + \log T). \quad \square
 \end{aligned}$$

Приложение к стохастической оптимизации. SGD. Будем рассматривать задачу условной оптимизации

$$\min_{x \in \mathcal{D}} f(x). \quad (3)$$

Однако, в отличие от стандартной выпуклой оптимизации, нам неизвестен точный градиент $\nabla f(x)$, а только его зашумленное представление $\tilde{\nabla}(x)$, которое удовлетворяет условиям

$$\mathbb{E}[\tilde{\nabla}(x)] = \nabla f(x), \quad \mathbb{E}[\|\tilde{\nabla}(x)\|^2] \leq G^2.$$

Таким образом, в каждой точке $x \in \mathcal{D}$ мы получаем случайный вектор, представляющий градиент $\nabla f(x)$, причем математическое ожидание этого вектора и есть градиент $\nabla f(x)$.

Метод стохастического градиента (SGD, stochastic gradient descent) устроен следующим образом:

- Задается начальное приближение $x_1 \in \mathcal{D}$, а также последовательность шагов $\{\alpha_t\}$.
- Для каждого раунда $t \in [1, T]$ итеративно выполняются следующие шаги:
 - наблюдается случайный вектор $\tilde{\nabla}(x_t)$ и по определению $f_t(x) \triangleq \langle \tilde{\nabla}(x_t), x \rangle$,
 - осуществляется сдвиг и проектирование в соответствии с OGD:

$$\begin{aligned} y_{t+1} &= x_t - \alpha_t \nabla f_t(x_t), \\ x_{t+1} &= \Pi_{\mathcal{D}}(y_{t+1}). \end{aligned}$$

- В качестве приближенного решения задачи (3) возвращается среднее значение от всех предсказаний

$$\bar{x}_T = \frac{1}{T} \sum_{t=1}^T x_t.$$

Теорема 3. SGD для переменного шага $\alpha_t = \frac{D}{G\sqrt{t}}$ обеспечивает оценку

$$\mathbb{E}[f(\bar{x}_T)] \leq \min_{x \in \mathcal{D}} f(x) + \frac{3GD}{2\sqrt{T}}.$$

Доказательство.

$$\begin{aligned} \mathbb{E}[f(\bar{x}_T)] - \min_{x \in \mathcal{D}} f(x) &= \mathbb{E}[f(\bar{x}_T)] - f(x_*) \leq \mathbb{E} \left[\frac{1}{T} \sum_{t=1}^T f(x_t) \right] - f(x_*) = \\ &= \frac{1}{T} \mathbb{E} \left[\sum_{t=1}^T (f(x_t) - f(x_*)) \right] \leq \frac{1}{T} \mathbb{E} [\langle \nabla f(x_t), x_t - x_* \rangle] = \\ &= \frac{1}{T} \mathbb{E} [\langle \tilde{\nabla}(x_t), x_t - x_* \rangle] = \frac{1}{T} \mathbb{E} [f_t(x_t) - f_t(x_*)] \leq \\ &\leq \frac{\text{regret}_T(\text{OGD})}{T} \leq \frac{3GD}{2\sqrt{T}}. \quad \square \end{aligned}$$

Упражнение 1. Покажите, что SGD для сильно выпуклых функций с соответствующим выбором переменного шага α_s сходится со скоростью $O(\log T/T)$.